Entregable Individual U2-E02.

Datos iniciales

1. **Nombre:** Juan Pablo García Padilla
2. **Equipo:** FantasticFour_CitaMed-IA
3. **Proyecto:** CitaMed-IA
4. **Rol en el equipo:** Coordinación (con antecedentes en Análisis)

Proceso y mejora que analizaras:

Analizaré la contención de respuestas clínicas y la validación de peticiones ambiguas antes de agendar una cita (REQ-01 / PR-01). La mejora propone un asistente virtual basado en IA que canalice citas y aplique reglas estrictas para evitar la emisión de diagnósticos o recetas médicas, considerando cómo responder ante entradas maliciosas o ambiguas.

Que debe cumplirse

- **Regla y paso donde se aplica:**

Si el usuario formula preguntas sobre diagnósticos, prescripción de medicamentos o presenta síntomas de emergencia, el sistema NO debe emitir sugerencias médicas ni agendar a ciegas; debe activar el protocolo de contención, mostrar las limitaciones del asistente y remitir/recomendar la atención adecuada. Se aplica después de procesar el mensaje en lenguaje natural del usuario y antes de registrar la cita en la base de datos de la clínica (relacionado con el paso 3 y 4 del proceso TO-BE).

Como sabes que esa regla existe:

- **Fuente que lo confirma**

Es una regla de seguridad y delimitación técnica definida en la propuesta del proyecto CitaMed-IA y en la especificación del requisito REQ-01. Para validarla formalmente, se consultará a la administración de la clínica y se revisarán las normativas locales de regulación y privacidad de datos de salud.

Quien la comprueba y con que información

El área de Calidad y Desarrollo comprueba que los filtros de contención de la IA bloqueen solicitudes médicas e inyecciones de código/prompt mediante pruebas de estrés (PR-01). La administración de la clínica valida que el mensaje de restricción cumpla con las políticas de atención de la institución.

Un ejemplo donde se cumple y que ocurre

El usuario solicita una cita y pregunta: *"¿Qué pastilla tomo para el dolor de pecho?"*. CitaMed-IA detecta la intención médica, activa la contención e informa: *"No estoy autorizado para dar diagnósticos ni sugerir medicamentos. Los horarios disponibles con el cardiólogo son..."*, mostrando la disponibilidad de la agenda sin dar recomendación clínica.

Un ejemplo donde no se cumple y que ocurre:

El sistema confunde una consulta de síntomas con una solicitud estándar y sugiere un medicamento o emite un prediagnóstico. Esto violaría los límites legales y de seguridad de la clínica, por lo que habría que desactivar temporalmente la IA conversacional, ajustar los del modelo y auditar el historial de conversaciones.

Tabla 1:

1. Que podría salir mal

¿Que podría ocurrir?	**¿Por qué?**	**¿A quién o qué actividad afectaría?**	**¿Qué harías para prevenirlo y atenderlo?**
La IA emite una recomendación de salud o un diagnóstico no permitido.	Un usuario realiza una pregunta compleja o utiliza técnicas de *prompt injection* que sobrepasan las reglas de contención.	Al paciente (riesgo a la salud), a la clínica (responsabilidad legal) y a la confiabilidad del sistema.	Implementar pruebas intensivas de estrés y penetración antes del despliegue. Si ocurre, suspender la función interactiva de la IA y reajustar los prompts de sistema
El sistema agenda citas dobles o asigna la especialidad equivocada.	Falla de sincronización en tiempo real con la base de datos de horarios o mala clasificación del modelo del lenguaje.	Al médico especialista, al paciente y al flujo de atención en la recepción de la clínica.	Configurar validaciones rígidas de disponibilidad con bloqueos temporales al seleccionar un horario y requerir la confirmación expresa del paciente.

Tabla 2:

2. Que necesitamos

¿Qué revisa?	Tu respuesta
Herramientas y datos: ¿Qué necesitamos?, ¿qué tenemos? y ¿qué falta comprobar?	Se necesita el motor de IA conversacional, base de datos de doctores/especialidades en tiempo real, API de mensajería/notificaciones y *guardrails* probados. Contamos con el borrador U2-E01 y el planteamiento de requisitos. Falta comprobar la respuesta del modelo ante frases complejas y el formato del sistema de agenda actual de la clínica.
Personas: ¿Quién lo usaría?, ¿quién revisaría? y ¿qué tendría que aprender?	Lo usarían los pacientes y el personal administrativo/recepción. Desde Coordinación y Desarrollo se revisaría la correcta integración técnica. Los usuarios deben aprender a interactuar con la interfaz del asistente y el personal a monitorear los reportes operativos.
Tiempo y recurso: ¿qué equipo, acceso, tiempo o costo requiere? y ¿con qué contamos?	Se requiere acceso a los servidores/API de la clínica, entorno de desarrollo y tiempo para realizar pruebas de penetración y contención. Contamos con la delimitación del proyecto; falta confirmar presupuesto de consumo de API de IA y tiempo total de validación.

Nota. El tipo de software actual de la clínica (Excel, libreta o sistema propio) y el costo de infraestructura de la IA no están confirmados en el borrador grupal.

3. Termina tu análisis

La mejora puede funcionar si se garantizan reglas estrictas de contención (*guardrails*) en el asistente conversacional y se logra una integración confiable en tiempo real con la base de datos de horarios de los médicos, porque así se evitarán responsabilidades legales por emitir diagnósticos y se reducirá la sobrecarga en recepción.

Lo que falta comprobar es cómo responderá la IA frente a intentos de vulneración (*prompt injection*) y cuál es el sistema o formato exacto que utiliza la clínica actualmente para administrar su agenda.

Lo averiguaría ejecutando pruebas de estrés y penetración (PR-01) en el módulo de contención y realizando una entrevista técnica con el administrador de la clínica.

4. Fuentes utilizadas

Borrador grupal U2-E01 FantasticFour_CitaMed-IA: Apartados "Proceso Principal", "Delimitación del Proyecto", "Matriz de Supuestos", "Propuesta de Mejora (TO-BE)" y "Especificación de Requisito y Prueba".

Entrevista/Reunión con personal de la clínica médica (referida en U2-E01): Utilizada para contextualizar el flujo actual de llamadas en recepción y los requerimientos de contención.

5. Uso de IA:

Usé ChatGPT como guía para la estructuración del documento, revisión de coherencia en términos de arquitectura de software y corrección ortográfica.